

theory

理論解説：状態空間モデルの導出とカルマンフィルタの位置付け

目次

(A・B 行列の導出) (#1-熱方程式から状態空間モデルへ)

- 1.1 出発点：熱伝導方程式 (PDE)
- 1.2 空間離散化：有限差分法 (FDM)
- 1.3 内部節点の方程式
- 1.4 境界節点の方程式 (対流境界条件)
- 1.5 行列形式への整理 (連続時間状態空間モデル)
- 1.6 観測方程式と観測行列 H
- 1.7 前進オイラー法による離散化：A_d・B_d の計算 (①なぜ必要か → ②前進差分の考え方 → ③離散化式の導出 → ④安定条件の確認 → ⑤実装)

タの理論的位置付け (#2-カルマンフィルタの理論的位置付け)

- 2.1 データ同化とは何か
 - 2.2 ベイズ推定としての解釈
 - 2.3 最小分散推定 (MMSE) としての導出
 - 2.4 カルマンゲインの物理的意味
 - 2.5 他の手法との位置関係
 - 2.6 工作機械熱誤差補償への応用
-

1. 熱方程式から状態空間モデルへ

1.1 出発点：熱伝導方程式 (PDE)

1 次元の熱棒における温度 $T(x, t)$ の時間発展は、**熱伝導方程式** (放物型偏微分方程式) で支配される：

$$\rho c_p \frac{\partial T}{\partial t} = k \frac{\partial^2 T}{\partial x^2} + \dot{q}(x, t)$$

記号	単位	意味
$T(x, t)$	°C	温度（位置・時刻の関数）
ρ	kg/m^3	密度
c_p	$\text{J}/(\text{kg} \cdot \text{K})$	比熱容量
k	$\text{W}/(\text{m} \cdot \text{K})$	熱伝導率
$\dot{q}$	W/m^3	体積発熱率（熱源）

熱拡散率 α を導入すると：

$$\alpha = \frac{k}{\rho c_p} \quad [\text{m}^2/\text{s}]$$

PDE は次のように書き直せる：

$$\frac{\partial T}{\partial t} = \alpha \frac{\partial^2 T}{\partial x^2} + \frac{\dot{q}}{\rho c_p}$$


物理的意味：左辺 $\partial T / \partial t$ は「温度の時間的な変化率」。右辺第 1 項は「空間的な温度の曲率に比例した熱拡散」、第 2 項は「熱源による温度上昇」を表す。

1.2 空間離散化：有限差分法（FDM）

PDE をコンピュータで解くために、空間方向 x を有限個の**節点**（node）に離散化する。

棒の全長 L を $n - 1$ 等分し、節点間距離を $\Delta x = L / (n - 1)$ とする：

$$x_i = i \cdot \Delta x, \quad i = 0, 1, \dots, n - 1$$



各節点の温度を $T_i(t) \equiv T(x_i, t)$ と表記する。

2 階微分の中心差分近似（テイラー展開から導出）：

$$\left. \frac{\partial^2 T}{\partial x^2} \right|_{x=x_i} \approx \frac{T_{i-1}(t) - 2T_i(t) + T_{i+1}(t)}{(\Delta x)^2} + O((\Delta x)^2)$$

導出：テイラー展開より

$$T_{i+1} = T_i + \Delta x \frac{\partial T}{\partial x} + \frac{(\Delta x)^2}{2} \frac{\partial^2 T}{\partial x^2} + \dots$$

$$T_{i-1} = T_i - \Delta x \frac{\partial T}{\partial x} + \frac{(\Delta x)^2}{2} \frac{\partial^2 T}{\partial x^2} + \dots$$

$$\text{辺々加算して } \frac{\partial^2 T}{\partial x^2} \approx (T_{i-1} - 2T_i + T_{i+1})/(\Delta x)^2$$

1.3 内部節点の方程式 ($i = 1, 2, \dots, n-2$)

内部節点では両隣の節点からの熱伝導のみが働く：

$$\frac{dT_i}{dt} = \frac{\alpha}{(\Delta x)^2} (T_{i-1} - 2T_i + T_{i+1})$$

ここで $r = \alpha/(\Delta x)^2$ と置くと：

$$\boxed{\frac{dT_i}{dt} = r T_{i-1} - 2r T_i + r T_{i+1}}$$

r は**拡散係数**（数値安定性の指標 $r \cdot \Delta t \leq 0.5$ が陽的差分の安定条件）。

本プログラムの値： $r = 1.2 \times 10^{-5}/(0.1)^2 = 1.2 \times 10^{-3} \text{ s}^{-1}$

1.4 境界節点の方程式（対流境界条件）

両端節点では、隣接節点からの**熱伝導**に加えて、周囲空気との**対流熱伝達**が働く。

Newton の冷却則（対流）：

$$q_{\text{conv}} = h_{\text{conv}}(T_i - T_{\text{amb}}) \quad [\text{W/m}^2]$$

■節点 0（左端：熱源 + 対流） エネルギーバランス（制御体積 Δx に対して）：

$$\rho c_p \Delta x \frac{dT_0}{dt} = \underbrace{k \cdot \frac{T_1 - T_0}{\Delta x}}_{\text{右隣からの熱伝導}} - \underbrace{h_{\text{conv}}(T_0 - T_{\text{amb}})}_{\text{対流冷却}} + \underbrace{\dot{q}_{\text{in}}}_{\text{熱源}}$$

$T_{\text{amb}} = 0$ （周囲温度を基準としてゼロ設定）として整理：

$$\frac{dT_0}{dt} = \underbrace{\frac{\alpha}{(\Delta x)^2}}_r (T_1 - T_0) - \underbrace{\frac{h_{\text{conv}}}{\rho c_p \Delta x}}_h T_0 + \underbrace{\frac{1}{\rho c_p \Delta x}}_b u$$

$$\boxed{\frac{dT_0}{dt} = -(r + h) T_0 + r T_1 + b u}$$

係数	定義	本プログラムの値
$r = \alpha/(\Delta x)^2$	拡散係数 [1/s]	1.2×10^{-3}
$h = h_{\text{conv}}/(\rho c_p \Delta x)$	対流係数 [1/s]	2.3×10^{-5}
$b = 1/(\rho c_p \Delta x)$	入力係数 [$\text{m}^3 \cdot \text{K}/\text{J}$]	2.86×10^{-7}

節点 $n - 1$ （右端：対流のみ） も同様：

$$\frac{dT_{n-1}}{dt} = r T_{n-2} - (r + h) T_{n-1}$$

1.5 行列形式への整理（連続時間状態空間モデル）

全節点の温度をベクトルにまとめる：

$$\boldsymbol{\theta}(t) = \begin{bmatrix} T_0(t) \\ T_1(t) \\ \vdots \\ T_9(t) \end{bmatrix} \in \mathbb{R}^{10}$$

全節点の微分方程式を行列形式で書くと：

$$\dot{\boldsymbol{\theta}} = \mathbf{A}_c \boldsymbol{\theta} + \mathbf{B}_c u$$

■ $\mathbf{A}_c$ 行列 ($n = 10$ の場合)

$$\mathbf{A}_c = \begin{bmatrix} -(r+h) & r & 0 & 0 & 0 \\ r & -2r & r & 0 & 0 \\ 0 & r & -2r & r & 0 \\ 0 & 0 & r & -2r & r \\ 0 & 0 & 0 & r & -(r+h) \end{bmatrix}$$

構造の特徴：

- 三重対角行列（tridiagonal）：隣接節点のみが結合
- 対角要素が負：各節点は熱を「失う」（散逸系）
- 対角外要素が正：隣接節点から熱が「来る」
- 両端の対角要素が内部節点より小さい：対流冷却の追加損失 $-h$

安定性： $\mathbf{A}_c$ は負定値行列（全固有値 < 0 ）であり、入力なし・断熱境界なら温度は必ず周囲温度に収束する。

■B_c 行列 熱源は節点 0 のみに集中：

$$\mathbf{B}_c = \begin{bmatrix} b \\ 0 \\ 0 \\ 0 \\ 0 \end{bmatrix} = \begin{bmatrix} 1/(\rho c_p \Delta x) \\ 0 \\ 0 \\ 0 \\ 0 \end{bmatrix}$$

入力 u は熱入力 Q [W/m] (単位奥行き当たりの線熱流束)。

1.6 観測方程式と観測行列 $\mathbf{H}$

センサは節点 0 と 9 のみに配置されているとする。観測方程式：

$$\mathbf{y}_k = \mathbf{H} \boldsymbol{\theta}_k + \mathbf{v}_k, \quad \mathbf{v}_k \sim \mathcal{N}(\mathbf{0}, \mathbf{R})$$

$$\mathbf{H} = \begin{bmatrix} 1 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 1 \end{bmatrix}$$

$\mathbf{H}$ は「どの節点を観測するか」を選択する行列。 $\mathbf{H} \in \mathbb{R}^{p \times n}$ (p : センサ数、 n : 節点数)。

可観測性条件： $\mathbf{H}$ と $\mathbf{A}_c$ (または $\mathbf{A}_d$) の組が可観測であること。

可観測行列 $\mathcal{O}$ がフルランクであれば、有限個のセンサで全状態が推定可能：

$$\text{rank}(\mathcal{O}) = \text{rank} \begin{pmatrix} \mathbf{H} \\ \mathbf{H}\mathbf{A}_d \\ \vdots \\ \mathbf{H}\mathbf{A}_d^{n-1} \end{pmatrix} = n$$

1.7 前進オイラー法による離散化： $\mathbf{A}_d \cdot \mathbf{B}_d$ の計算

この節では「なぜ離散化が必要か」という動機から始め、前進差分の考え方を使って離散化行列を導出し、最後に安定条件の確認と実装を説明する。

■ステップ① なぜ離散化が必要か 熱系の物理モデルは連続時間の微分方程式 (ODE) で書かれている：

$$\dot{\boldsymbol{\theta}}(t) = \mathbf{A}_c \boldsymbol{\theta}(t) + \mathbf{B}_c u(t)$$

しかし現実のセンサとコンピュータは離散的な時刻でしか動作しない。

$\theta(t)$ が滑らかに変化

$\theta_0, \theta_1, \theta_2, \dots$ の列として扱う


$\begin{array}{ccccc} \uparrow & & \uparrow & & \uparrow \\ t=0 & & t=\Delta t & & t=2\Delta t \end{array} \leftarrow \Delta t \text{ ごとにサンプル}$

目標: 「時刻 $k \cdot \Delta t$ の状態 θ_k から、次の時刻 $(k+1) \cdot \Delta t$ の状態 θ_{k+1} を直接計算する漸化式」を求めること。

$$\theta_{k+1} = \mathbf{A}_d \theta_k + \mathbf{B}_d u_k$$

■ステップ② 前進差分の考え方 微分 $\dot{\theta} = d\theta/dt$ を、前進差分で近似する:

$$\left. \frac{d\theta}{dt} \right|_{t=k\Delta t} \approx \frac{\theta_{k+1} - \theta_k}{\Delta t}$$



これを状態方程式 $\dot{\theta} = \mathbf{A}_c \theta + \mathbf{B}_c u$ に代入すると:

$$\frac{\theta_{k+1} - \theta_k}{\Delta t} = \mathbf{A}_c \theta_k + \mathbf{B}_c u_k$$

■ステップ③ 離散化式の導出 両辺に Δt をかけて θ_{k+1} を左辺に移項する:

$$\theta_{k+1} = \theta_k + \Delta t (\mathbf{A}_c \theta_k + \mathbf{B}_c u_k)$$

$$= (\mathbf{I} + \mathbf{A}_c \Delta t) \theta_k + \mathbf{B}_c \Delta t u_k$$

これにより離散化行列が得られる:

$$\boxed{\mathbf{A}_d = \mathbf{I} + \mathbf{A}_c \Delta t, \quad \mathbf{B}_d = \mathbf{B}_c \Delta t}$$

意味： $\mathbf{I}$ は「現在の温度をそのまま持ち越す」部分、 $\mathbf{A}_c \Delta t$ は「 Δt 秒間の熱拡散による温度変化」を加える部分。

スカラー例 ($\dot{\theta} = -a\theta + bu$) で確認：

連続系	離散化後
a	$A_d = 1 - a\Delta t$
b	$B_d = b \Delta t$

■ステップ④ 安定条件の確認 前進オイラー法には安定条件がある。スカラー版 $A_d = 1 - a\Delta t$ が安定には $|A_d| < 1$ が必要：

$$|1 - a\Delta t| < 1 \implies 0 < a\Delta t < 2$$

行列版では、 $\mathbf{A}_d = \mathbf{I} + \mathbf{A}_c \Delta t$ の全固有値の絶対値が 1 未満であること：

$$|\lambda_i(\mathbf{A}_d)| = |1 + \lambda_i(\mathbf{A}_c) \Delta t| < 1$$

離散化方法	安定条件	備考
前進オイラー法（陽的）	$r \cdot \Delta t \leq 0.5$	本プログラムで使用
後退オイラー法（陰的）	無条件安定	計算が複雑（逆行列が必要）
ZOH（行列指数関数）	無条件安定	<code>scipy.linalg.expm</code> が必要

本プログラムの安定性確認：

$$r \cdot \Delta t = \frac{\alpha}{(\Delta x)^2} \Delta t = \frac{1.2 \times 10^{-5}}{(0.1)^2} \times 10 = 1.2 \times 10^{-3} \times 10 = 0.012 \ll 0.5 \quad \checkmark$$

$\Delta t = 10\text{s} \cdot dx = 0.1\text{m}$ の条件では十分安定であることが確認できる。

■ステップ⑤ 実装（Python コード） 前進オイラー法の実装は行列の加算・乗算だけで済む：

```
import numpy as np

n = 10 # 状態数（節点数）

# A_d = I + A_c · Δ t
A_d = np.eye(n) + A_c * dt


# B_d = B_c · Δ t
B_d = B_c * dt
```

`scipy` などの外部ライブラリは不要。`numpy` だけで計算できる。

2. カルマンフィルタの理論的位置付け

2.1 データ同化とは何か

データ同化 (Data Assimilation) とは、物理モデルの予測と実際の観測データを統計的に最適な方法で融合し、システムの状態をより正確に推定する手法である。



データ同化は元々**気象予報**（大気・海洋の数値シミュレーション）で発展した。現在は工学・医学・経済学など広範囲に応用されている。

本研究での位置付け：FEM デジタルツイン（物理モデル）＋温度センサ計測値（観測）→ 工作機械の全温度場推定

2.2 ベイズ推定としての解釈

カルマンフィルタは **ベイズ推定 (Bayesian Estimation)** の特殊ケースとして厳密に導出できる。

■ベイズの定理

$$\underbrace{p(\boldsymbol{\theta}_k | \mathbf{y}_{0:k})}_{\text{事後分布}} \propto \underbrace{p(\mathbf{y}_k | \boldsymbol{\theta}_k)}_{\text{尤度}} \times \underbrace{p(\boldsymbol{\theta}_k | \mathbf{y}_{0:k-1})}_{\text{事前分布}}$$

項	意味	カルマンフィルタでの表現
事前分布	モデル予測から得られる信念	$\mathcal{N}(\hat{\boldsymbol{\theta}}_k^-, \mathbf{P}_k^-)$
尤度	センサ計測がその状態から生成される確率	$\mathcal{N}(\mathbf{H}\hat{\boldsymbol{\theta}}_k^-, \mathbf{R})$
事後分布	計測後に更新された信念	$\mathcal{N}(\hat{\boldsymbol{\theta}}_k, \mathbf{P}_k)$

ガウス分布の積はガウス分布であることを利用すると、更新式は解析的に解ける：

$$p(\boldsymbol{\theta}_k | \mathbf{y}_{0:k}) = \mathcal{N}(\hat{\boldsymbol{\theta}}_k, \mathbf{P}_k)$$

$$\hat{\boldsymbol{\theta}}_k = \hat{\boldsymbol{\theta}}_k^- + \mathbf{K}_k (\mathbf{y}_k - \mathbf{H}\hat{\boldsymbol{\theta}}_k^-)$$

$$\mathbf{P}_k = (\mathbf{I} - \mathbf{K}_k \mathbf{H}) \mathbf{P}_k^-$$

これがカルマンフィルタの更新式そのものである。つまり、カルマンフィルタは線形ガウス系に対する「ベイズ推定の閉形式解」である。

2.3 最小分散推定 (MMSE) としての導出

カルマンゲイン $\mathbf{K}_k$ を「推定誤差の分散を最小化する」条件から導出する。

目標：推定誤差の共分散行列のトレース (= 平均二乗誤差の和) を最小化する：

$$\min_{\mathbf{K}_k} \text{tr}(\mathbf{P}_k) = \min_{\mathbf{K}_k} \text{tr} \left[(\mathbf{I} - \mathbf{K}_k \mathbf{H}) \mathbf{P}_k^- (\mathbf{I} - \mathbf{K}_k \mathbf{H})^\top + \mathbf{K}_k \mathbf{R} \mathbf{K}_k^\top \right]$$

$\mathbf{K}_k$ で微分してゼロとおく ($\partial \text{tr}(\mathbf{P}_k) / \partial \mathbf{K}_k = 0$)：

$$-2(\mathbf{I} - \mathbf{K}_k \mathbf{H}) \mathbf{P}_k^- \mathbf{H}^\top + 2\mathbf{K}_k \mathbf{R} = 0$$

$$\mathbf{K}_k (\mathbf{H} \mathbf{P}_k^- \mathbf{H}^\top + \mathbf{R}) = \mathbf{P}_k^- \mathbf{H}^\top$$

$$\boxed{\mathbf{K}_k = \mathbf{P}_k^- \mathbf{H}^\top \underbrace{(\mathbf{H} \mathbf{P}_k^- \mathbf{H}^\top + \mathbf{R})^{-1}}_{\text{イノベーション共分散}^{-1}}}$$

これがカルマンゲインの式である。この $\mathbf{K}_k$ は線形不偏推定量の中で分散最小 (MVUE: Minimum Variance Unbiased Estimator) であることが証明されている。

2.4 カルマンゲインの物理的意味

カルマンゲイン $\mathbf{K}_k$ は「モデル予測とセンサ計測の信頼度の比」で自動的に決まる重みである。

$$\hat{\boldsymbol{\theta}}_k = \underbrace{\hat{\boldsymbol{\theta}}_k^-}_{\text{モデル予測}} + \mathbf{K}_k \underbrace{(\mathbf{y}_k - \mathbf{H} \hat{\boldsymbol{\theta}}_k^-)}_{\text{イノベーション (予測残差)}}$$

■2つの極端なケース **ケース1：センサが非常に正確 ($\mathbf{R} \rightarrow 0$) **

$$\mathbf{K}_k \rightarrow \mathbf{H}^+ \quad (\mathbf{H} \text{ の擬似逆行列}) \implies \hat{\boldsymbol{\theta}}_k \approx \mathbf{H}^+ \mathbf{y}_k \quad (\text{センサを全信頼})$$

**ケース2：モデルが非常に正確 ($\mathbf{P}_k^- \rightarrow 0$) **

$$\mathbf{K}_k \rightarrow 0 \implies \hat{\boldsymbol{\theta}}_k \approx \hat{\boldsymbol{\theta}}_k^- \quad (\text{モデル予測を全信頼})$$

一般的なケース (最適バランス)：

モデル不確かさ P が大きい $\longrightarrow$ K が大きい $\longrightarrow$ センサを重視
 センサノイズ R が大きい $\longrightarrow$ K が小さい $\longrightarrow$ モデルを重視


直感的な理解：GPS と地図を使ったナビゲーションに例えると、

- GPS 信号が弱いとき (R 大) $\rightarrow$ 地図 (モデル) を重視
- 地図が古いとき (P 大) $\rightarrow$ GPS (センサ) を重視
- カルマンフィルタはこの「どちらをどれだけ信頼するか」を最適に計算する

2.5 他の手法との位置関係

■データ同化手法の分類

データ同化



■各手法の比較

手法	対象系	計算コスト	必要条件	工作機械への適合性
標準 KF	線形・ガウス	低	線形性	○ (小規模・線形なら最適)
EKF	弱非線形	中	ヤコビアン計算可	◎ (温度依存材料特性に対応)
UKF	中程度非線形	中	—	◎ (高精度・コード簡潔)
EnKF	強非線形・高次元	高	アンサンブル数	△ (FEM の全状態にそのまま適用困難)
粒子フィルタ	任意	非常に高	—	△ (リアルタイムに不向き)

■ルエンベルガーオブザーバとの対比 制御工学ではルエンベルガーオブザーバ（状態推定器）が知られている：

$$\hat{\theta}_{k+1} = \mathbf{A}_d \hat{\theta}_k + \mathbf{B}_d u_k + \underbrace{\mathbf{L}}_{\text{ゲイン（設計者が決める）}} \left(\mathbf{y}_k - \mathbf{H} \hat{\theta}_k \right)$$


カルマンフィルタはルエンベルガーオブザーバの特殊ケースであり、ゲイン $\mathbf{L} = \mathbf{K}_k$ が**ノイズ統計量 $\mathbf{Q}, \mathbf{R}$ から最適に計算される点が異なる**。

■変分型データ同化（4D-Var）との等価性 時間窓が無限に長い場合、カルマンフィルタの解は 4D-Var（最適制御問題として定式化するデータ同化）の解と等価になることが知られている。

2.6 工作機械熱誤差補償への応用

本プログラムが模擬する論文（Lang et al., 2024）との対応を整理する。

■役割分担



■本手法の優位性

課題	従来のデータ駆動手法	カルマンフィルタ + FEM
訓練データ	大量の実験データが必要	不要（FEM が代替）
センサ数	多数必要（16 本など）	少数可能（4 本で 83% 補償）
汎化性	学習条件外で劣化	FEM の物理的制約により頑健
リアルタイム更新	困難（再学習必要）	自然に対応（逐次更新）

■今後の拡張方向

テーマ	内容
適応 KF	$\mathbf{Q}$ をオンラインで更新し、FEM モデル誤差を吸収
EKF への拡張	温度依存の材料特性（非線形 $\mathbf{A}_c$ ）に対応

センサ配置最適化	可観測性グラミアン $\mathcal{W}_o = \sum_{k=0}^{\infty} (\mathbf{A}_d^k)^\top \mathbf{H}^\top \mathbf{H} \mathbf{A}_d^k$ を最大化する $\mathbf{H}$ を設計
OpenFOAM 連成	CFD (流体・熱連成) 解析から $\mathbf{A}_c, \mathbf{B}_c$ を抽出

まとめ：A・B 行列とカルマンフィルタの関係

$$\underbrace{\text{熱方程式 (PDE)} \xrightarrow{\text{FDM 空間離散化}} \dot{\boldsymbol{\theta}} = \mathbf{A}_c \boldsymbol{\theta} + \mathbf{B}_c u \xrightarrow{\text{前進オイラー離散化}} \boldsymbol{\theta}_{k+1} = \mathbf{A}_d \boldsymbol{\theta}_k + \mathbf{B}_d u_k}_{\text{FEM デジタルツイン (物理モデル)}}$$

↓ カルマンフィルタに入力

$$\underbrace{\hat{\boldsymbol{\theta}}_k = \hat{\boldsymbol{\theta}}_k^- + \mathbf{K}_k (\mathbf{y}_k - \mathbf{H} \hat{\boldsymbol{\theta}}_k^-)}_{\text{データ同化} \rightarrow \text{熱変位の推定 (補償値の計算)}} \xrightarrow{\delta = \alpha_{\text{exp}} \sum_i \hat{\theta}_i \Delta x} \hat{\delta}_k$$

A・B 行列はデジタルツインが保持する「物理知識の結晶」であり、カルマンフィルタはその知識とセンサ情報を最適に融合する「推論エンジン」である。